

Práctica 7 SIW - Documentación

Pelayo Sierra Lobo UO294217

PageRank

Esta práctica consistía en implementar un recomendador de películas basado en la base de datos de MovieLens. Para ello, se utiliza el script `recommender.py` junto con un pequeño archivo `utils.py`. A continuación documento algunas consideraciones que se hicieron en la elaboración de este script.

Esta práctica se fue construyendo poco a poco, primero desarrollando un recomendador general de las mejores películas, pasando por un subgrafo de películas vistas por las mismas personas que vieron una película consulta, para terminar teniendo en cuenta tanto el género como el ranking medio de la película.

Primeramente, hay una función `get_movie_by_title` que busca la película introducida a través de la terminal. No necesita hacer un match completo, simplemente lo suficiente como para inferir la película que se busca. Por ejemplo, para **Close Encounters of the Third Kind** basta con escribir *"close enc"*.

La función principal que construye el grafo de películas es `build_local_graph`, a partir del subconjunto de películas vistas por los usuarios que han visto la película consulta. Primero, genera una lista de ids de películas filtradas por los usuarios, para luego aplicar la distancia de Jaccard a sus géneros:

```
...
users_who_watched = RATINGS.loc[RATINGS["movieId"] == movie_id,
"userId"].unique()
local_ratings = RATINGS[RATINGS["userId"].isin(users_who_watched)]
mean_ratings = ( # Se calculan las valoraciones medias para más adelante
    local_ratings.groupby("movieId")["rating"]
    .mean()
    .to_dict()
)
filtered_movie_ids = sorted(local_ratings["movieId"].unique())
filtered_movie_ids, genre_jaccard_map =
build_jaccard_map(filtered_movie_ids)
...
```

Después, la función genera un diccionario de co-ocurrencias solo entre las películas del subconjunto. Para cada usuario, se toman todas las combinaciones posibles de películas vistas y se cuentan las apariciones conjuntas.

Así, se construye un grafo en el que los nodos son las películas filtradas, con atributos `movieId` y `genre_jaccard`. El peso de cada arista representa cuántos usuarios comparten esas dos películas (basado en el número de co-ocurrencias).

Las valoraciones medias se utilizan para generar pesos de personalización normalizados, de modo que se tienen en cuenta a la hora de calcular el PageRank más adelante. De esta manera se indica la importancia inicial de cada película, y PageRank le da más peso a películas mejor valoradas.

```
# Grafo local
g = ig.Graph()
g.add_vertices(len(filtered_movie_ids))
g.vs["movieId"] = filtered_movie_ids
g.vs["genre_jaccard"] = [genre_jaccard_map[mid] for mid in
filtered_movie_ids]

personalization = build_personalization(filtered_movie_ids, mean_ratings)

id_to_index = {mid: idx for idx, mid in enumerate(filtered_movie_ids)}
edges_filtered = []
weights_filtered = []

for (a, b), w in movie_pairs.items():
    if a in id_to_index and b in id_to_index:
        edges_filtered.append((id_to_index[a], id_to_index[b]))
        weights_filtered.append(w)

g.add_edges(edges_filtered)
g.es["weight"] = weights_filtered
```

Por último, la función `compute_local_pagerank` se encarga del cálculo final y de ordenar las películas. Se utiliza la función `personalized_pagerank` de `igraph` para aplicar la personalización, y se genera un `DataFrame` con el ID de cada película, su título y su puntuación de Jaccard basada en sus géneros.

La puntuación final se basa en una ponderación sencilla:

- $\alpha \text{ pagerank_norm} + (1-\alpha) \text{ genre_jaccard}$

Donde `pagerank_norm` es el valor de PageRank normalizado, y `genre_jaccard` es la puntuación de Jaccard mencionada previamente. Este valor α se añade como parámetro, aunque es igual a 0,7 por defecto.

Los resultados finales se guardan en un archivo `.txt` de la siguiente manera:

```
movieId,title,genres,pagerank_norm,final_score
```

Ejemplos

Existe una carpeta con ejemplos de ejecuciones en la entrega (ejemplos). Estos incluyen tanto películas vistas por un gran número de usuarios del dataset, como es el caso de **Terminator 1**, como películas vistas por poca gente, como **Walled In**, vista solo por una persona de la colección.