

Práctica 5 SIW - Documentación

Pelayo Sierra Lobo UO294217

Búsqueda semántica

En esta práctica se ha desarrollado un buscador léxico con el objetivo de detectar documentos duplicados a partir de *embeddings* para el dataset de Quora, utilizando ChromaDB para indexar la base de datos de preguntas.

Se han utilizado los embeddings pre-calculados ofrecidos en el enunciado del ejercicio, y, a partir de la demo `demo-chromadb.py`, se adaptó el script para procesar la colección de Quora y calcular los valores necesarios (VP, FP, FN, precisión, exhaustividad y F1).

El modelo utilizado para los embeddings es `google/embeddinggemma-300m`. La parte del script que compara los embeddings de las distintas preguntas para encontrar posibles duplicados es la siguiente:

```
def process_queries(collection, records):
    dup_set = set()
    dup_count = 0
    avg_distance = 0

    for record in tqdm(records, desc="Looking for duplicates..."):
        query_text = record["text"]
        query_id = str(record["id"])
        results = collection.query(query_texts=[query_text], n_results=10)
        for doc_id, doc_text, dist in zip(results["ids"][0],
results["documents"][0], results["distances"][0]):
            if doc_id != query_id and dist < DUPLICATE_THRESHOLD:
                avg_distance += dist
                pair = tuple(sorted([query_id, doc_id]))
                if pair not in dup_set:
                    dup_set.add(pair)
                    dup_count += 1

    avg_distance = avg_distance/dup_count
    print(f"Number of duplicates found: {dup_count}")
    print(f"Average distance between duplicates: {avg_distance}")
    return dup_set
```

El propósito de esta función es generar un *set* de parejas (tuplas) de preguntas posiblemente duplicadas como se hacía para la tarea de *Simhash*, que luego analizaremos y evaluaremos mediante los mismos métodos empleados para aquella tarea.

Experimentación y análisis

En el script existe una constante `DUPLICATE_THRESHOLD` que sirve para establecer un límite de distancia entre vectores para que estos sean considerados duplicados. Para esta experimentación, se probó con distancias de `0.20`, `0.25` y `0.30`.

 El archivo `questions_with_embeddings.ndjson` debe ser añadido manualmente a la carpeta `embeddings_quora`, ya que ocupa demasiado espacio como para ser incluido en la entrega.

Threshold de 0.20

```
Number of duplicates found: 70801
Average distance between duplicates: 0.1952597001235658

...

RESULTS FOR QUORA COLLECTION
VP = 38782
FP = 32019
FN = 26064
Precision = 0.5477606248499315
Recall = 0.5980631033525584
F1 = 0.5718077067683031
```

Threshold de 0.25

```
Number of duplicates found: 104378
Average distance between duplicates: 0.2326892862763946

...

RESULTS FOR QUORA COLLECTION
VP = 42219
FP = 62159
FN = 22627
Precision = 0.40448178734982465
Recall = 0.651065601579126
F1 = 0.4989717770529003
```

Threshold de 0.30

```
Number of duplicates found: 144650
Average distance between duplicates: 0.2650791840078589

...
```

```
RESULTS FOR QUORA COLLECTION
VP = 43518
FP = 101132
FN = 21328
Precision = 0.3008503283788455
Recall = 0.6710976775745613
F1 = 0.4154542330163822
```

Se puede observar que, conforme aumenta el límite, aumentan los valores de VP (Verdaderos Positivos), por lo que se encuentran más duplicados (y por ende disminuye el valor de FN). Aun así, también aumenta el número de Falsos Positivos, ya que se consideran como duplicadas preguntas que realmente no lo son.

Debido a esto, parece que a mayor valor de `DUPLICATE_THRESHOLD`, menor valor de `F1`. Esto se debe a que, a pesar de que aumente el valor de Exhaustividad (Recall), la precisión disminuye notablemente, afectando de manera negativa al valor de `F1`. Debido a esto, con este modelo específico, quizás lo más óptimo es mantenerse por debajo del límite de 0.25. Otra opción sería buscar y emplear un modelo diferente de embeddings que se adapte mejor a la búsqueda de preguntas duplicadas, lo cual requeriría un análisis y estudio de las distintas posibilidades.

Es muy notable la diferencia de resultados entre esta práctica y la de Simhash. En la Práctica 3, el mejor valor obtenido fue `F1 = 0.013564615643706845`, para una tolerancia extremadamente alta (`Tolerance = 7`). En aquel caso, el valor de VP fue de 443, mientras que para esta práctica el valor más alto de `F1` fue `0.5718077067683031`, con un valor de VP aproximadamente igual a 40000.

Esto hace evidente la diferencia entre aplicar técnicas léxicas y semánticas a distintas colecciones. La colección de Quora, concretamente, contiene muchos duplicados a nivel de significado (no léxico), por lo que se produce una mejora muy notable al utilizar embeddings como en este caso (una diferencia del 4116.4%).